

2026CIKM

Abstract Submission Deadline: April 10, 2026, 11:59 p.m.

Full Paper Submission Deadline: April 17, 2026, 11:59 p.m. Anywhere on Earth (AoE)

Decision Notification: Early July 2026

1.Motivation:

备份部分文件：

UniMiss: Unifying Heterogeneous Missingness Mechanisms for Multivariate Time Series Imputation

Anonymous Author(s)

No Institute Given

1 **Abstract.** Multivariate Time Series (MTS) are ubiquitous and inevitably
2 contain missing values. To this end, MTS Imputation (MTSI) has emerged,
3 aiming to estimate missing values based on observed data for reliable
4 downstream tasks. Although previous MTSI studies have made progress
5 on performance enhancement, they are based on an unrealistic assumption:
6 treating missing values as random noise. In fact, real-world MTS
7 missing values are generated based on realistic underlying causes such
8 as dependencies among observed variables or the intrinsic characteristics
9 of the missingness itself, giving rise to heterogeneous missingness patterns.
10 Therefore, recognizing these patterns and unifying the modeling
11 of them is essential for practical MTSI. Moreover, an intuitive insight
12 is that **the missing representation varies dynamically as the underlying**
13 **missingness mechanism changes.** On top of both these motivations, we
14 propose UniMiss, a novel and practical framework with two key innovations.
15 First, we propose the Mask-Aware Temporal Encoder (MATE)
16 to explicitly incorporate the missingness dependencies inherent in different
17 missingness mechanisms, overcoming biased imputation. Second,
18 we propose the Spatial Mechanism-Coupled Decoder (SMCD) to dynamically
19 balance between intra-missing and missing-observed dependencies, ensuring
20 robust and mechanism-consistent imputation. Empirically, extensive experiments
21 demonstrate that UniMiss achieves state-of-the-art performance across various
22 real-world datasets while exhibiting lightweight design, high scalability, and
23 robustness. Our code is available
24 at [CodeLink](#).

25 1 Introduction

26 Multivariate Time Series (MTS) data are ubiquitous in modern systems like
27 meteorological monitoring [2] and power grids, [17], where they serve as the
28 foundation for downstream tasks such as MTS forecasting [14] and classification [15].
29 In practice, however, the prevalence of missing values within MTS poses a
30 significant challenge, as incomplete observations can propagate errors and severely
31 degrade downstream performance [1]. As a result, Multivariate Time Series
32 Imputation (MTSI), which estimates missing values from partially observed data,
33 has emerged as a vital task for ensuring high-quality MTS.

Motivation1:

现有的方法将缺失本身视为random noise，忽略了对缺失本身的利用，尽管有些方法利用MAR和MANR作为Benchmarks，但它们不是专门针对这些缺失机制设计的；（注意他们的方法有进行observed-to-miss的建模）

但我们要强调的是对缺失本身的建模（Intra-miss）（M-M）

M1：显式并联合的建模缺失依赖：包括缺失间的依赖+缺失与可观测依赖（M-M；M-O）

另外我们的工作同时也要建模可观测数据之间的上下文（可观测-可观测）（O-O）

这里值得注意的点是：

我们的工作与前人工作的最大区别在于：建模缺失间的依赖（这里怎么建模，怎么可以用图表达出来，怎么针对于我们极值和周期的问题建模都要考虑）

再就是，我们和前人一样建模了缺失与可观测（O-M）的依赖关系，那么我们与前人的不同点在哪里？以及我们如何强调这种联合关系

Motivation2:

在基于M1的想法之后，我们便要思考在联合建模之后，会遇到的问题：

也就是MAR和MNAR会共同存在于现实缺失场景中，但是这种可观测-缺失以及缺失-缺失变量之间的空间关系（变量间相关性）会随着机制发生变化；

也就是说，这种缺失的依赖不是静态不变的，而是会随着机制不同产生变化的

M2：要从空间角度（变量间）联合建模，机制驱动的缺失依赖！

简单来说：就是模型在MAR和MNAR的Mix场景下，能够感知出缺失机制更倾向于哪种机制，如果更倾向于MAR，则更倾向于使用缺失-可观测依赖；如果更倾向于MNAR，则更倾向于使用缺失间依赖；

Motivation 2: In mixed missingness settings, different missing positions may require different recovery dependencies, so a uniform imputation rule is fundamentally insufficient.

在混合缺失场景下，不同缺失位置所需的恢复依赖不同，因此采用统一、静态的插补不合理

- MAR下：缺失可以通过周围的可观测值，其他变量和时间上下文来推断当前缺失，此时更信O-M，因为O-M本质是在做：当前Missing Position 需要什么Observed evidence
- MNAR下：缺失往往和缺失值本身或其潜在状态相关，**不是简单靠周围有观测就能补出来**

它可能和极端值，异常波动，峰谷某种Missing topology（缺失拓扑：缺失位置之间的结构关系，变量之间共同缺失的模式和连接关系）有关，此时只靠可观测的数据不够，甚至会把关键的信息平均掉，此时应该更信M-M；

因为**M-M本质是在建模：当前Missing Position正处在什么缺失结构中**

总体而言，而前人工作是不区分的，模型会默认所有缺失位置都遵循同一种恢复逻辑，但在现实混合场景中，不同位置对可观测值/缺失结构的依赖本身就不同！因此才要有机制选择的软门控模块；

目前来看主要有三个图可以画：

- MAR/MNAR的样例场景图（注意对应的文字解说也要有，图也要形象）
- Motivation1对应图（注意对于我们的核心模块要具象化出来）
- Motivation2对应图（同样对于我们的核心部件要具象化表示出来）

也就是说在设计模型的时候就要注意到这一点，想一下具体的模块设计该怎么做，又可以怎么表达

2.Method:

2.0：现有Baseline思考：

BRITS：典型的OM主导方法

Motivation：

BRITS的出发点是，传统 RNN 插补流程往往先对缺失值做静态预填充，再把结果送入时序模型，这会把“插补”和“时序建模”人为拆开，导致模型无法在递归过程中动态修正缺失值。它要解决的核心问题是：怎样让缺失值在序列传播过程中被反复更新，而不是被一次性固定。

创新点：

BRITS的关键创新有两个。第一，把缺失值视为递归图中的变量，在 forward / backward 两个方向上持续更新，而不是只做输入端预处理。第二，引入 temporal decay 与双向一致性，使模型能够根据时间间隔衰减历史信息，并利用双向恢复结果互相校正。

方法论：

从方法结构看，BRITS 以 observed trajectory 为主干，利用 RNN hidden state 在时间维上传播上下文，然后让当前时刻的缺失位置借助隐藏状态与最近观测值得到恢复。这个过程对 `OM` 是明显显式的，因为缺失值的恢复直接依赖 observed history；对 `OO` 只有弱隐式支持，因为 observed-observed 关系只是通过 recurrent hidden state 被压缩进统一状态里；对 `MM` 则基本没有单独建模，缺失位置之间的关系不会被抽成独立机制。

OO / OM / MM 判断：`BRITS` 是非常典型的 `OM` 主导 baseline。它确实利用了 observed context，但这种利用方式主要服务于 observed-to-missing 恢复，而非 missing-side pattern extraction。

ImputeFormer：OO + OM 联合建模，但 MM仍是隐式

Motivation：

ImputeFormer 面对的问题是，RNN 类方法对长程依赖的表达能力不足，而简单的 Transformer 直接套到缺失场景又容易忽略 mask 结构和插补任务本身的特殊性。因此它要解决的是：**如何让时序长依赖、变量间依赖和缺失恢复在同一 backbone 中协同工作。**

创新点：

它的代表性创新在于将 imputation 任务与 Transformer 表征耦合起来，不再把“建模时序”与“恢复缺失”分成完全独立的两步。相比早期方法，**ImputeFormer 更强调时间维与变量维的联合表示**，以及在 attention 结构中显式保留 mask 相关信息，使观测上下文可以更稳定地流向待恢复位置。

方法论：

从结构上看，ImputeFormer 的 backbone 更像 unified encoder：observed tokens 之间通过 self-attention 形成 `OO` 上下文，missing positions 再通过同一表征空间吸收 observed 信息完成恢复，因此它是比较典型的 `OO + OM` 联合方法。问题在于，`MM` 并没有被单独写出来。**missing positions 之间即使存在相关性，也只是通过共享 self-attention 间接传播，没有专门的 missing-side prompt、router 或 pattern expert。**

`OO / OM / MM` 判断：`ImputeFormer` 的 `OO` 与 `OM` 都较强，但 `MM` 仍停留在共享 backbone 的隐式传播层面，不足以支撑我们要强调的 missing-missing 专门建模。

FGTI：最接近 `MM` 动机的生成式 baseline，但仍未显式专家化

Motivation：

FGTI 的核心出发点是，高缺失率、块缺失或复杂缺失模式下，单一确定性点估计容易过平滑，也难以表达“同一 observed context 可能对应多个合理恢复值”的不确定性。**它尝试解决的问题不是简单的 observed-to-missing 回归，而是缺失分布本身的生成式建模。**

创新点：

它的重要贡献在于把生成式恢复或扩散式恢复引入时间序列插补，使模型不再只输出一个静态点估计，而是通过逐步去噪或条件生成逼近缺失位置的合理分布。相较于纯判别式恢复，这种设计更接近我们所说的“不能只靠 observed context 平滑恢复”的动机。

方法论：

从当前项目中的 FGTI.py 与相关模型实现看，它的恢复流程依赖条件信息、mask 信息以及生成式 denoising 过程来重建目标位置。这里确实开始触及 `MM`：因为多个缺失位置之间的相互约束可以在同一生成过程里被共同建模，而不是逐点独立恢复。但需要特别强调的是，**FGTI 的 `MM` 是“生成过程隐式产生的 missing-side coupling”**，而不是显式的 `MM branch`、`MM expert bank` 或 `MM router`。因此它是 Unimiss 中 `MM` 设计最强的 baseline 启发来源，但还不能替代显式 `MM` 模块。

‘OO / OM / MM’ 判断：‘FGTI’ 对 ‘OM’ 和 ‘MM’ 都有帮助，其中对 ‘MM’ 的启发最大；但它的 ‘MM’ 仍然是 generative latent interaction，而不是论文级明确拆出的 missing-pattern module。

SPIN：典型 ‘OO’ 强方法，辅以 mask-aware 初始化

Motivation：

SPIN 关注的问题是，很多插补方法把时序依赖和变量间关系混在一个统一序列里处理，导致空间结构或变量拓扑没有得到充分利用。它想解决的是：如何把时序传播与变量图传播结合起来，使 observed context 更稳定地支撑恢复。

创新点：

从项目中的 ‘SPIN.py’ 与 ‘models/spin_model.py’ 可以看到，‘SPIN’ 的重要创新包括 graph-aware temporal propagation、mask-aware initialization，以及对 observed / missing 状态使用不同嵌入。它的重点不是新建 missing-side pattern branch，而是让 observed context 在图与时序两个维度上都被更充分传播。

方法论：

SPIN通过图结构边连接变量节点，在时间维与空间维进行交替传播，并用 mask-aware 初始化区分 observed 与 missing 状态。这个结构对 ‘OO’ 很强，因为 observed-observed 关系在 temporal-spatial propagation 中被反复强化；对 ‘OM’ 有一定支持，因为 missing node 会从 observed node 获得信息；但它依然没有为 missing positions 单独建立内部结构抽取模块，因此 ‘MM’ 基本缺位。

OO / OM / MM判断：‘SPIN’ 最适合被归入 ‘OO’ 强 baseline。它告诉我们 observed context 应该如何更结构化传播，但并没有把 missing-side pattern 写成独立主线。

SAITS：最典型的 observed-missing attention 融合方法

Motivation：

SAITS 针对的是自回归插补效率低、误差容易逐步累积的问题。它希望把 self-attention 的并行建模优势带到插补任务中，并让模型在一个统一结构里同时完成上下文建模与缺失恢复。

创新点：

SAITS 的关键在于采用自注意力模块来替代严格自回归链路，并通过针对缺失场景设计的输入组织方式与训练目标，使 observed tokens 可以更直接地为 missing tokens 提供信息。相较于 RNN 系方法，它的注意力传播更全局、更并行。

方法论：

方法上，`SAITS` 仍然遵循“observed context 为主、missing positions 从 observed context 中取信息”的基本逻辑。也就是说，它对 `OM` 建模是明确且强的；对 `OO` 也有支撑，因为 observed tokens 之间通过 self-attention 建立全局依赖；但 `MM` 仍然没有被拆成单独模块，缺失位置之间如果出现相关性，也只是共享 attention 结构的副产品。

OO / OM / MM 边界判断：SAITS 属于 `OM` 融合非常典型的 baseline。它有助于解释 why shared attention can help imputation，但也正因为它把一切放进共享注意力里，所以难以体现 missing-side specialization。

TimesNet：提供周期模式先验，但不是 missing-specific 结构

Motivation：

TimesNet 要解决的是时间序列中的多周期模式、局部变化与全局变化同时存在，单一时域建模很难把这些模式拆开。因此它更关注“时间模式本身如何表示”，而不是“缺失关系如何分解”。

创新点：

它的代表性创新是把 1D 时间序列变换到更适合表达周期变化的表示空间中，再利用多尺度卷积或周期建模模块抽取 pattern。对插补任务而言，这类设计的价值在于：如果缺失本身带有显著周期性，周期 backbone 可以为恢复提供弱结构先验。

方法论：

在当前实验设定里，`TimesNet` 作为插补 baseline 时，并不会显式构造 `OM` 或 `MM` 路由，而是把整个序列送入一个强时间模式提取 backbone，再由其输出恢复结果。因此它对 `OO` 有一定支撑，对 `OM` 只是间接支持，而对 `MM` 的价值主要体现为“周期 missing pattern 的弱先验”，而非 missing-side explicit interaction。

OO / OM / MM 判断：`TimesNet` 不能被写成真正的 `MM` 方法，但它确实提供了 Unimiss 里 `periodic MM prompt source` 的局部灵感来源。

MTSCI：生成式一致性视角下的 missing coupling

Motivation：

MTSCI 所面对的问题与 `FGTI` 相近，即单一路径、单点预测式恢复在复杂缺失场景下容易不稳定，尤其难以处理需要多步修正和全局一致性的恢复过程。它试图增强的是“恢复结果的一致性与稳定性”，而不只是一次性回归误差。

创新点：

从当前项目中的 `MTSCI.py`、`models/model.py` 与 `models/model\_predict\_x0.py` 可以看到，`MTSCI` 引入了 diffusion / denoising-style 恢复路径与一致性约束，利用多种 mask 视角、条件信息

和去噪步骤来约束恢复过程。它的重要意义在于提醒我们：missing-side relation 不一定只能靠 deterministic attention 学到，也可以通过生成式一致性来间接塑形。

方法论：

方法上，MTSCI通过条件 mask、预测 mask、反向条件 mask 等多种视图组织训练过程，在 denoising network 中逐步恢复目标值。这种做法对 `OM` 有一定支持，因为 observed information 仍是条件恢复的主要来源；对 `MM` 也有中等启发，因为多个缺失位置可以在同一生成/去噪链路中被共同约束；但它依然没有像 Unimiss 那样把 `MM` 写成显式专家化结构。

OO / OM / MM 边界判断：`MTSCI` 可以被视为“生成式一致性约束视角”的 baseline，对 `MM` 有启发但不等于显式 `MM` 模块。

Overall：

- 前人大多数方法仍默认 `X\_{miss}` 的恢复主要来自 `X\_{obs}` 的信息传递，即便 backbone 形式从 RNN、Transformer、Graph propagation 变成 diffusion 或 periodic modeling，这个总假设并没有根本改变。因此，`OM` 是主线，`OO` 是支撑，`MM` 很少被抬升为 headline。
- 即使 `FGTI`、`MTSCI`、`TimesNet` 这类方法在生成式恢复、周期模式或一致性约束层面开始触及 missing-side structure，它们也没有把 `MM` 拆成显式 branch / expert / router。也就是说，前人会“碰到 `MM`”，但不会“把 `MM` 当成需要专门建模的对象”。
- 在当前常见缺失机制设置下，前人大都采用统一恢复流程：同一套 backbone 同时处理 `MAR / MNAR / Mix`。这意味着方法不会显式回答“当前应该更依赖 `OM` 还是 `MM`”，更不会设计一个单独的 second-stage mechanism-aware regulation 去动态调节两者权重。
- 前人方法大多仍遵循同一条恢复逻辑：先在共享 backbone 中混合 observed-observed context 与 observed-to-missing interaction，再让 missing positions 从统一表征空间中吸收信息；即便某些方法通过生成式恢复、周期先验或一致性约束间接触及 missing-side coupling，它们也很少把 MM 提升为一个显式、可路由、可解释的核心结构模块；更没有在 MAR / MNAR / Mix 共存时单独回答“当前应更依赖 observed-side 交互还是 missing-side 结构”

UniMiss 的创新恰恰是把这三类信息流重新拆开：OO 不再承担所有恢复责任，也不被写成第三个重型 expert family，而是被保留为 foundational context path，专门提供稳定的 observed-side 基础；OM 被重写为 interaction-oriented expert branch，由 OM prompt 决定应该调用哪类 observed 信息；MM 被显式提升为 missing-structure expert branch，专门建模 co-missing topology、periodic evidence 与 extreme-event clue，而不再让 missing-side pattern 仅作为共享 backbone 或生成过程中的隐式副产物；在此基础上，Stage-II mechanism-aware MAR-vs-MNAR soft gate 不再保留第四套独立 prompt encoder，而是由 MM prompt 再结合轻量 local/global missingness summary 派生出 gate prompt，据此动态调节 OM 与 MM 的相对权重，而不是像前人那样沿用一套静态恢复链路处理所有机制。因此，UniMiss 的核心贡献不是“再增加一些 experts”，而是把缺失插补重写成 OO foundational context path + OM/MM dual-core experts + Stage-II mechanism-aware MAR-

vs-MNAR soft gate 的分层体系，用结构分工显式回答三个过去常被混写的问题：谁提供稳定上下文、谁建模不同类型的缺失依赖、以及在 MAR 与 MNAR 混合场景下模型应当优先依赖哪一条路径。

特别提一下O-O和O-M的创新：

前人在O-O上：

把observed-side context吸收到统一 backbone 里，让 observed representation 一边服务自身编码，一边同时服务 missing recovery，OO 更像 shared background，而不是单独被强调的结构角色

而我们：

显式的把他单独抽出来，仅负责提取稳定的可观测上下文，不是与Missing-side decision（决定O-M）混合在一起处理！为后续的O-M和M-M提供稳定的上下文

UniMiss 则先单独保留`OO foundational context path`，让模型先回答“observed world 本身长什么样”，再让后续`OM / MM`去决定如何利用这份基础上下文。

前人在O-M上：

前人处理 observed-to-missing interaction，通常是：用统一 attention / cross-attention / shared encoder默认 observed information 会自然流向 missing positions；**对所有的缺失位置都用同一套 attention 计算，导致每个Missing position从周围observed values吸收到的信息是被均匀混合的，把所有的observed 表征混在一起，算一组统一的权重！**

也就是说，他们不会进一步思考：当前缺失位置到底需要哪类可观测的evidence？不同的缺失位置应该调用不同的可观测上下文

而我们UniMiss 把 O-M 重写成：

OM evidence-demand prompt

OM router

OM experts

也就是说，不止是用了Experts这么简单，而是先思考，当前这个缺失得position需要什么可观测的值？再决定：


是应该更依赖于同变量局部时间？还是跨变量相关，还是说其他的可观测的交互逻辑？

对于短缺失段，最有价值的证据往往是同变量的局部时间邻域；对于跨变量强耦合的缺失点，更重要的是相关变量的同步 observed pattern；对于噪声较大的 observed 区域，即使有邻域信息，也需要先经过可靠性校准再参与恢复。

missing position 先形成自己的 OM prompt，再由这个 prompt 决定应该调用哪种 observed evidence processing strategy

不同缺失位置不再被迫共享同一套 observed interaction 规则，而是能够根据自身需求动态选择更合适的 observed evidence experts

2.1: 方法论overview (点对点) + 模型图



- **基础输入层**：将数值，时间，变量，掩码mask投影到统一特征空间，形成融合特征
- **O-O上下文主干**：从融合特征中筛选当前位置及其邻域的Token/Patch；抽取局部波动，跨变量，周期等作为O-O_Prompt；随后使用Encoder在Prompt约束下生成稳定的O-O Context
- **O-M交互专家层**：对每个待imputation位置提取局部Mask形态，缺失块统计和邻域可观测的信上下文息，与O-O Context形成 O-M_Prompt；为该缺失位置聚合与之最相关的observed邻域信息，而不是直接读取整条共享表征；根据匹配Prompt和与Observed的匹配关系，对每个Experts输出软权重；不同Experts分别处理：**同变量局部时间，跨变量相关性和可靠性校准**；将上述Experts的输出按软权重组合生成最终的O-M特征；
- **M-M缺失结构专家层**：从Mask矩阵构造co-missing graph，捕获变量之间共同缺失的结构关系；从极端值，周期性，缺失拓扑生成M-M_Prompt；根据Prompt和O-O Context联合语义，对各类Experts输出软权重；分别处理**拓扑结构，周期性和极值相关**的Missing Patterns；输出Z-Z特征；
- **Soft-Gate**：直接读取MM_Prompt，并结合轻量的缺失块统计描述量，投影成为向量Gate；对O-M和M-M两条核心分支输出权重，最后在保留O-O的前提下，对M-M和O-M进行机制感知的动态调节；

每个Expert都类似于lightweight prompt-conditioned evidence extraction blocks

对应设计：

O-O+O-M+M-M针对Motivation1设计，实现联合的特征提取建模；对于O-M和M-M采用Expert架构，并考虑到：不同缺失位置对Observed Evidence和Missing-structure的需求不同

Soft-Gate对应Motivation2设计，在混合缺失场景下，不同缺失位置所需的恢复依赖不同，针对MAR和MNAR进行动态调节；

2.2：方法论详述：

1.输入、掩码与模块归属

设原始时间序列为：

$$X \in \mathbb{R}^{T \times D}$$

其中 T 为时间长度， D 为变量数。定义观测掩码：

$$M \in \{0, 1\}^{T \times D}$$

其中 $M_{t,d} = 1$ 表示该位置 observed， $M_{t,d}=0$ 表示该位置 missing。

基础嵌入层写作：

$$H_0 = \phi(X, M, E_t, E_d)$$

其中：

- E_t 为 time embedding
- E_d 为 variable embedding
- $\phi(\cdot)$ 为 value-time-mask fusion module

这一步只负责把原始输入映射到统一表征空间。

为了把方法写到论文级细度，必须明确每个模块到底是“已有通用模块”还是“本文创新模块”：

模块	角色	具体功能	创新归属
value-time-mask fusion	基础输入层	将数值、时间、变量、mask 投影到统一特征空间	通用模块
shared observed encoder + 00 prompt	00 主干	提供带 observed-pattern prompt 的 observed-only 主干上下文	本文在结构角色上做了重构，模块主体仍属基础 backbone
OM prompt encoder + OM router + OM experts	OM 核心	对 observed-to-missing 交互做 prompt-conditioned routing	本文主创新，借鉴 Flex-MoE / I2MoE

MM prompt encoder + MM router + MM experts	MM 核心	对 missing-side topology / extreme-value / periodic pattern 做 prompt-driven 专家化建模	本文主创新，借鉴 Flex-MoE / Time-MoE / I2MoE
mechanism-aware gate head	Stage II	由 MM prompt + lightweight missingness summary 派生 gate prompt，并对 OM / MM 做 soft regulation	本文主创新，借鉴 Soft MoE / Lingual-SMoE
branch decoupling	正则层	防止 OO / OM / MM 表征塌缩为同一语义空间	本文迁移式创新
decoder	输出层	将融合表征映射为最终插补值	通用输出层

2.Stage I: OO foundational branch

OO 是 foundational context path，不是 heavyweight expert family；它的创新主要体现在 structural role 与 pattern-aware observed-side anchoring。

2.1 Problem role

OO 这条路径要解决的不是“如何直接恢复缺失值”，而是一个更基础的问题：**在整条序列已经存在缺失噪声的前提下，如何先把 observed side 本身的真实结构组织稳定。** 如果这一步缺失，后续 `OM` 与 `MM` 两条 expert branches 的 routing 就只能在一个被缺失任务污染、被统一 backbone 混写的表征空间上做决策，最终会出现两类问题：

- 1. OM 会把并不稳定的 observed cue 当成可靠证据，导致 observed-to-missing interaction 选择失真。
- 2. MM 会逐渐脱离真实 observed context，只剩下基于 mask pattern 的形状匹配，缺乏数据语义约束。

因此，OO 的目标是先构造一个稳定、低噪声、带 pattern-awareness 的 observed context anchor。

2.2: Module decomposition

OO foundational context path 建议明确写成下面 3 个连续模块，而不是一句“使用编码器提取上下文”：

1. observed token selection

- 从基础融合表征 H_0 中筛出当前位置及其邻域的 observed-side token/patch;
- 目的不是重建, 而是建立仅由真实观测值支撑的上下文基础。

2. pattern-aware observed context extraction

- 对每个位置抽取局部波动、跨变量相关、周期对齐等 **observed-side prompt signal**;
- 这些 prompt signal 不是 expert routing 信号, 而是 foundation path 的 inductive bias。

3. foundational context encoding

- 用共享 observed encoder 在上述 `00 prompt` 约束下生成 z_i^{oo} ;
- 输出只承载稳定的 observed-observed context, 不承担缺失恢复主决策。

对第 i 个 token/patch 的输入表征 h_i , 定义 foundational context encoder:

$$z_i^{\text{oo}} = E^{\text{oo}}(h_i, p_i^{\text{oo}})$$

然后构造 `00 prompt`:

$$p_i^{\text{oo}} = [\Delta_i; \rho_i; \pi_i]$$

其中:

- Δ_i : 局部波动强度
- ρ_i : 跨变量相关性摘要
- π_i : 周期对齐得分

更细地说, 建议把这三个量理解为:

$$\Delta_i = \text{VarPool}(\mathcal{N}_i^{\text{time}}), \quad \rho_i = \text{CorrPool}(\mathcal{N}_i^{\text{var}}), \quad \pi_i = \text{PeriodScore}(\mathcal{N}_i^{\text{time}})$$

其中 $\mathcal{N}_i^{\text{time}}$ 表示位置 i 周围的时间邻域 observed window, $\mathcal{N}_i^{\text{var}}$ 表示与变量 d_i 相关的变量邻域 observed window。它们的作用不是形成新专家, 而是让 `00` 编码器显式知道当前位置更接近平稳趋势、周期振荡还是局部异常。

这里的 p_i^{oo} 不是为了形成第三个 expert pool, 而是作为 pattern-aware inductive bias, 帮助 `00` encoder 在 observed-only context 中更稳定地区分:

- 平稳趋势
- 周期波动
- 局部突变
- 跨变量同步变化

这一步借鉴 `TIME-MOE + Moirai-MoE` 的不是 forecasting decoder 和大规模专家池, 而是:

- `shared + specialized decomposition`
- `point / patch level pattern specialization`

- 不同局部时间模式不应共用完全同一个提取器

但迁移到 Unimiss 后，这种思想不会被实现成一个独立 observed-side expert family，而是收敛为一个带 pattern-aware inductive bias 的 `foundational context path`。因此，`OO` 的创新边界应被写成：

- `not a heavyweight expert family`
- `not a plain shared encoder either`
- `its novelty lies in structural role and constrained observed-side anchoring`

2.3: Explanation of every symbol

- H_0 ：基础输入融合后的统一隐藏表征，已经包含数值、时间位置、变量身份与 mask 状态。
- h_i ：从 H_0 中取出的第 i 个局部 token/patch 表征，是 `OO` 路径的直接输入。
- $\mathcal{N}_i^{time}$ ：位置 i 周围的时间邻域 observed 集合，用于估计局部波动与周期性。
- $\mathcal{N}_i^{var}$ ：与变量 d_i 相关的变量邻域 observed 集合，用于估计跨变量同步关系。
- Δ_i ：局部波动强度，反映该位置附近 observed 序列是平稳还是高变化。
- ρ_i ：跨变量相关性摘要，反映该变量在当前时窗内与其他变量是否存在同步变化。
- π_i ：周期对齐得分，反映当前位置是否与候选周期结构一致。
- p_i^{oo} ：由三类 observed-side signal 拼接而成的 `observed-pattern prompt`。
- $E^{oo}(\cdot)$ ：`OO foundational encoder`，其职责是把 h_i 与 p_i^{oo} 融合成稳定的 observed context representation，而不是生成缺失恢复输出。
- z_i^{oo} ：第 i 个位置的 `observed-observed context anchor`，后续 `OM / MM` 都在其约束下工作。

2.4: Why does it works

`OO` 看起来不像一个重型模块，但它的有效性恰恰来自**结构位置正确**而不是参数复杂度高。前人大多数做法把 observed context 直接混进统一 backbone，于是 observed-observed relation、observed-to-missing interaction 与 missing-side effect 会在同一表征空间里纠缠，最终 observed context 很容易被“恢复缺失值”这一目标稀释。**UniMiss 则先单独保留`OO foundational context path`，让模型先回答“observed world 本身长什么样”，再让后续`OM / MM`去决定如何利用这份基础上下文。**这样做有三个直接收益：第一，后续 routing 始终建立在稳定 observed anchor 上，而不是建立在被缺失噪声污染的混合表征上；第二，`OM`在选择 observed cue 时有了明确参考系，不会把无关 observed pattern 误选为恢复证据；第三，`MM`在建模 missing-side structure 时仍然受到真实观测语义约束，不会退化成只按 mask 形状分群。也因此，`OO`的价值不在于“它有多复杂”，而在于**如果没有这条路径，整套模型后续的专家选择就缺少可靠地基。**

2.5: Difference from prior OO design

与前人最大的区别在于：前人通常让所有 **observed pattern** 被共享 **backbone** 隐式混合，**OO** 只是一个未被点名的背景；而我们明确把 **OO** 留成一个独立的 foundational path，使后续 **OM / MM** 的重专家位点始终建立在稳定 context 之上，但不把它抬升为第三个核心 expert family。这正是它“既不太弱，也不越位”的原因。

3. Stage I: OM branch

OM branch 的目标是显式建模 observed-to-missing interaction。这里必须明确：**OM** 是一个 expert family，而不是一个单块 attention。

3.1: Problem role

OM 要解决的核心问题是：对于某一个具体缺失位置，模型到底应该从哪些 **observed cues** 中取信息。这一步如果继续沿用 prior work 中“让 missing token 从共享 backbone 自然吸收 observed context”的写法，就会把所有缺失位置都绑定到同一套 observed aggregation 规则上，无法区分“短 gap 和长 gap 需要不同线索”“平稳段和异常段需要不同 observed evidence”这类关键差异。因此，`OM` 必须从“共享交互”升级为“条件化选择”。

3.2: Module decomposition

OM interaction-oriented expert branch 建议明确写成下面 5 个连续模块：

1. **OM prompt construction**
 - 对每个待恢复位置提取局部 mask 形态、缺失块统计、邻域 observed 摘要与来自 **OO** 的基础上下文。
2. **observed candidate summarization**
 - 为该缺失位置聚合与之最相关的 observed 邻域信息，而不是直接读整条共享表征。
3. **prompt-conditioned router**
 - 根据 **OM prompt** 与 observed anchor 的匹配关系，对各个 **OM experts** 输出软权重。
4. **expertized observed interaction**
 - 不同 experts 分别处理局部时间传播、跨变量相关和可靠性校准。
5. **branch aggregation**
 - 将上述 experts 的输出按软权重组合成最终的 z_i^{om} 。

对每个待插补位置构造 **OM prompt**：

$$p_i^{\text{om}} = \psi_{\text{om}}(m_i, r_i, \bar{x}_i^{\text{nb}}, z_i^{\text{oo}})$$

其中：

- m_i 为局部 mask pattern
- r_i 为缺失块位置、长度、邻域统计等 prompt source
- $\bar{x}_i^{nb}$ 为邻域 observed summary
- z_i^{oo} 为 foundation path 输出
- $\psi_{om}(\cdot)$ 为 OM prompt encoder

如果要把这一步讲清楚，建议把 observed 邻域摘要显式写成：

$$\bar{x}_i^{nb} = \text{Agg}(\{x_j \mid j \in \mathcal{C}_i^{obs}\})$$

其中 $\mathcal{C}_i^{obs}$ 表示为缺失位置 i 检索到的 observed candidate set, `Agg` 可以是局部均值、加权池化或轻量 attention，但其目的不是替代 router，而是先给 router 一个可用的 observed summary。

然后构造 `OM router`：

$$w_i^{om} = \text{Softmax}(\text{MLP}([p_i^{om}; z_i^{oo}; p_i^{om} \odot z_i^{oo}]))$$

最终 `OM` 表征为：

$$z_i^{om} = \sum_{k=1}^{K_{om}} w_{i,k}^{om} E_k^{om}([p_i^{om}; z_i^{oo}]), \quad K_{om} = 3$$

该分支明确区别于前人的统一 attention：

- 前人：observed context 自然流向 missing position
- 我们：**由缺失模式驱动 observed-missing interaction routing**

`OM` 内部不应只写“有 experts”，而应明确至少三类：

1. `local temporal propagation expert`
 - 恢复同变量局部邻域缺失
2. `cross-variable correlation expert`
 - 恢复由相关变量支撑的 missing token
3. `reliability calibration expert`
 - 对 observed cue 的可信度做重加权，避免错误传播

进一步解释：

前两个专家是在回答：**从哪里借信息来补缺失；**

但是他们都基于一个隐含假设：**借来的observed信息是可信的，但很有可能信息不可信**

什么时候信息不可信：

- **邻域本身存在剧烈波动**：当可观测数值本身处在异常波动期时，数值跳来跳去，如果直接用它们做局部平均来补，则补出来的值会被噪声污染

- **相关变量处于边缘状态**：变量A缺失了，如果想用强相关的B变量来imputation，但B变量此时恰好处于极端值区间，它和A正常相关关系可能已经失效了
- **缺失率很高的区域**：如果一个位置周围大量邻居缺失，剩下少量的observed代表性很差，直接使用可能会引入偏差

因此可信专家负责给每条信息打分数，对不可靠的信息降低权重

这一步主要吸收 Flex-MoE + I2MoE 的：

- generalized + specialized router
- observed context + prompt 联合路由
- interaction-aware experts

因此，OM 的创新不是“再做一次 cross-attention”，而是让 OM prompt 决定 observed cues 的选择和组合顺序。这样写法更符合正式论文方法论，也更能体现与 BRITS / SAITS / ImputeFormer 这类 prior methods 的边界。

3.3: Explanation of every symbol

符号解释：

- i ：当前待恢复的缺失位置索引，可以对应一个 token、patch 或具体时序坐标 (t,d) 。
- m_i ：位置 i 附近的局部 mask pattern，描述该位置是否处于连续缺失块、孤立缺失点或混合缺失区间。
- r_i ：缺失块统计描述量，例如块长度、起止位置、最近观测距离与局部缺失率。
- C_i^{obs} ：为缺失位置 i 检索到的 observed candidate 集合，是 OM 可以调用的原始 observed 证据池。
- $\bar{x}_i^{nb}$ ：由 C_i^{obs} 聚合得到的邻域 observed summary，表示当前位置周围可利用的 observed context 摘要。
- z_i^{oo} ：来自 00 foundational context path 的 observed-side anchor，表示在不考虑当前缺失需求之前，observed 世界本身的稳定结构。
- $\psi_{om}(\cdot)$ ：OM prompt encoder，用于把 mask 形态、缺失统计、邻域 observed 摘要和 foundation anchor 压成统一 evidence-demand prompt。
- p_i^{om} ：第 i 个缺失位置的 OM prompt，表达“这个位置当前最需要哪类 observed 证据”。
- $p_i^{om} \odot z_i^{oo}$ ：缺失需求与 observed anchor 的逐元素交互项，用于度量两者在表征空间中的匹配程度。
- $MLP(\cdot)$ ：router 网络，将联合输入映射为 expert logits。
- w_i^{om} ：第 i 个位置对 OM experts 的软分配权重，决定当前缺失位置更依赖哪种 observed interaction strategy。
- K_{om} ：OM expert 数。

- $E_k^{om}(\cdot)$: 第 k 个 OM expert, 各自学习不同类型的 observed-to-missing interaction。
- z_i^{om} : OM branch 的最终输出, 表示经过条件选择和专家聚合后的 observed-to-missing interaction representation。

3.4: Why does it works

OM 的有效性来自一个非常直接但常被 prior work 混掉的事实: 不是所有 observed cues 都适合所有 missing positions。对于短缺失段, 最有价值的证据往往是同变量的局部时间邻域; 对于跨变量强耦合的缺失点, 更重要的是相关变量的同步 observed pattern; 对于噪声较大的 observed 区域, 即使有邻域信息, 也需要先经过可靠性校准再参与恢复。共享 backbone 或统一 attention 的问题在于, 它默认这些情况都可以用同一套 observed aggregation 规则处理, 于是“该选哪类 observed evidence”这一决策被平均掉了。UniMiss 的 `OM` 则把这个决策显式化: 先用 p_i^{om} 描述缺失需求, 再让 router 根据 p_i^{om} 与 z_i^{oo} 的匹配关系决定 expert 权重。这样一来, 模型不是被动等待 observed 信息自然流向 missing position, 而是主动判断“当前这个缺失位置最该调用哪种 observed interaction”。这也是为什么 `OM` 看起来仍然只是一条 branch, 却比 generic cross-attention 更有针对性、更可解释。

3.5: Difference from prior OM design

前人方法中的 OM 多数是附带交互: observed 信息在共享主干里自然传播, missing position 被动接收。我们的 OM 则明确改成 prompt-conditioned evidence selection, 即先定义缺失需求, 再做 observed cue 选择。换言之, 前人是在“让信息流过去”, 而我们是在“决定哪些信息应该流过去、以什么方式流过去”。

4. Stage I: MM missing-structure expert branch

根据最新冻结结构, MM 不再是轻量辅助 branch, 而是第二个核心 expert branch。它的任务是显式建模 missing-side structure, 尤其服务 MNAR。

4.1: Problem role

MM 要解决的问题是: 当恢复目标本身带有强 missing-side structure 时, 模型不能只从 observed side 借信息, 而必须显式回答 missing positions 彼此之间存在什么结构关系。这一点在 `MNAR`、长块缺失、周期性缺失和极值相关缺失场景下尤其重要。若没有 `MM`, 模型会默认所有恢复都应优先依赖 `OO + OM`, 从而把真正有意义的 co-missing topology、periodic pattern 和 extreme-event clue 重新压回共享主干中的弱先验。

4.2 Module decomposition

MM missing-structure expert branch 建议明确写成下面 5 个连续模块:

1. missing topology construction
 - 从 mask 矩阵构造 co-missing graph, 捕获变量之间共同缺失的结构关系。
2. MM prompt construction

- 从极端值线索、周期线索与缺失拓扑中抽取 MM prompt 的主结构信号。

3. MM routing head

- 根据 MM prompt 与 oo anchor 的联合语义，对各类 MM experts 输出软权重。

4. pattern-specialized MM experts

- 分别处理 topology、periodic 与 extreme-value / anomaly 相关的 missing pattern。

5. amplitude calibration head

- 在 MNAR 或极值相关场景下输出幅度校正系数，避免恢复被过度平滑。

首先，从掩码矩阵构建缺失拓扑图：

$$A_{u,v}^{miss} = \frac{\sum_{t=1}^T (1 - M_{t,u})(1 - M_{t,v})}{\sum_{t=1}^T (1 - M_{t,u}) + \epsilon}$$

它表示变量 u 与变量 v 的 co-missing 强度。

然后构造三类 MM prompt source：

1. topology summary

- 由 A^{miss} 聚合得到

2. extreme-value clue

- 峰值、谷值、尖峰、异常波动与幅值突变相关线索

3. periodic evidence

- 若干候选周期下的 phase consistency / lag hit

先将它们编码为 MM prompt：

$$p_i^{mm} = \psi_{mm}([z_i^{oo}; s_{topo}; s_{ext}; s_{per}])$$

随后构造 MM router：

$$w_i^{mm} = \text{Softmax}(\text{MLP}_{mm}([p_i^{mm}; z_i^{oo}]))$$

再由一组 missing-pattern experts 聚合：

$$z_i^{mm} = \sum_{k=1}^{K_{mm}} w_{i,k}^{mm} E_k^{mm}([z_i^{oo}; p_i^{mm}]), \quad K_{mm} = 3$$

其中 $E_k^{mm}(\cdot)$ 建议由三类 pattern specialists 组成：

1. topology expert

- 负责 co-missing topology encoder
2. periodic expert
 - 负责 periodic memory bank
 3. extreme-value / anomaly-aware expert
 - 负责极大值、极小值、尖峰与异常波动附近的 missing pattern 建模

最后一个组件直接回应 2026SDM.pdf 第五章“不要把 MM 又做回平滑 attention”的要求。更具体地，我们令 MM branch 额外输出极值放大系数：

$$a_i = \sigma(W_a z_i^{mm})$$

使得在 MNAR 相关位置上，模型允许比普通平滑插补更大的偏移幅度。

这一设计直接回扣 2026SDM 第五章最关键的态度：发现缺失具有极值性或周期性还不够，必须把这些信息真的转成可用于插补的结构化信号；否则方法本质上仍然是在利用 observed context 做平滑恢复。

这里借鉴 MoE 工作的细节也要写清：

- 从 Flex-MoE 借来的是“不同组合模式对应不同专家”的思想
- 从 Time-MoE 借来的是“不同时间模式应由不同专家处理”的思想
- 从 I2MoE 借来的是“prompt source 之间的交互可作为 expert selection 依据”的思想

但我们没有照搬任何原论文的完整任务设定，而是把它们重新组织到 missing-side pattern experts 这一新语境下。

4.3: Explanation of every symbol

把关键量说明白：

- $A_{u,v}^{miss}$ ：变量 u 与 v 的 co-missing 强度，表示两条变量在时间维上共同缺失的相对频率。
- u, v ：变量索引，而不是时间位置索引。
- s_{topo} ：由缺失拓扑图聚合得到的 topology summary，反映 missing-side 的结构连接模式。
- s_{ext} ：extreme-value clue，反映当前位置是否靠近峰值、谷值、尖峰、异常振幅或剧烈波动区段。
- s_{per} ：periodic evidence，反映缺失分布与候选周期的对齐程度。
- i ：当前待恢复的位置索引。
- z_i^{oo} ：来自 00 foundational context path 的 observed-side anchor，用于给 missing-side 建模提供语义约束。

- $\psi_{mm}(\cdot)$: MM prompt encoder，统一编码 topology、extreme-value 与 periodic 线索。
- p_i^{mm} : 位置 i 的 MM prompt，表达“当前 missing position 更像哪一种 missing-side structure”。
- w_i^{mm} : 位置 i 对各个 MM experts 的软路由权重，决定当前位置更应依赖哪一类 missing-side structure。
- K_{mm} : MM expert 数。
- $E_k^{mm}(\cdot)$: 第 k 个 MM expert，分别建模 topology、periodic 或 extreme-value / anomaly 相关的 missing pattern。
- z_i^{mm} : 位置 i 的 missing-structure representation，是 missing-side 显式建模的主输出。
- a_i : 极值放大系数，用于在 MNAR 或极值相关缺失场景下避免恢复结果被过度平滑。
- $\sigma(\cdot)$: Sigmoid 激活，将极值校正项约束在稳定范围内。

4.4: Why does it works

MM 这条分支之所以必要，是因为 prior work 即使触及 missing-side coupling，也大多把它放在生成过程、周期先验或一致性正则里做隐式建模，结果是模型知道“这里可能有 missing pattern”，却没有一个显式模块去决定哪一种 missing-side structure 才是当前真正有价值的恢复信号。在 `MNAR`、长块缺失、周期性缺失或极值相关缺失场景下，这个缺口尤其明显：如果只依赖 `OO + OM`，模型仍会更倾向于从 observed side 做平滑恢复，从而把真正有意义的 missing topology、extreme-value clue 与 periodic evidence 重新抹平。UniMiss 将 `MM` 升成显式 `missing-structure expert branch` 后，missing-side information 不再是弱先验，而是成为可以被编码、被路由、被聚合、被校正的主恢复信号之一。也因此，`MM` 的有效性不在于“我们也加了专家”，而在于它第一次把 missing-side structure 从辅助背景提升为与 `OM` 并列的核心决策来源。

4.5: Difference from prior MM design

前人如果触及 MM，大多是隐式触及：要么在生成式恢复里让缺失位置共同去噪，要么在周期先验或一致性项里间接约束 missing-side relation，但很少把 MM 明确升级为可编码、可路由、可解释的独立结构模块。UniMiss 的不同点在于：我们不再把 missing-side pattern 当成附带副产物，而是把它明确重写成 missing-structure expert branch，使其在 MNAR 与复杂缺失场景下拥有与 OM 并列的恢复话语权。

5: Stage I: 表征解耦

为了避免 OO / OM / MM 三条分支退化到同一空间，按照第五章关于 contrastive decoupling 的建议，引入分支分离正则。

定义：

$$\mathcal{L}_{sep} = \mathcal{L}_{con}(z^{oo}, z^{om}) + \mathcal{L}_{con}(z^{oo}, z^{mm}) + \mathcal{L}_{con}(z^{om}, z^{mm})$$

其中 $\mathcal{L}_{con}$ 可以采用对比式分离损失或去相关损失，使 MM 不再复制 OO 的上下文表征。

5.1 Why it works

如果没有表征解耦，OO / OM / MM 虽然在结构图上被画成三条分支，但在训练后很可能仍然塌缩到相近语义空间，最后形成“名义上分工、实际上同质”的伪拆分。这样一来，OM 无法真正学到 observed-to-missing interaction，MM 也无法稳定保留 missing-side structure，整个架构只是在统一 backbone 上挂了几个不同名字的头。L_{sep} 的作用正是防止这种退化：它迫使 OO 维持 observed anchor 的角色，迫使 OM 聚焦 interaction-specific cues，迫使 MM 保留 missing-side pattern 的专门表示。也就是说，解耦项不是可有可无的辅助正则，而是保证三条路径真正分工的训练约束。

6: Stage II: mechanism-aware MAR-vs-MNAR soft gate

第二阶段是本方法的另一个核心创新。必须明确写成：它就是一种 MoE-style gate，但不是第三个 expert family，本身不产生新的依赖表征，只负责给 OM / MM 分配软权重。

6.1: Problem role

Stage-II 要解决的问题不是“再生成一条新表征”，而是：****当不同位置对应不同缺失机制时，模型应当如何动态决定更依赖`OM`还是更依赖`MM`****。如果没有这一层，模型就只能对`MAR / MNAR / Mix`全部沿用同一套静态融合规则，最终会把机制差异压平，导致`OM`与`MM`虽然都存在，却无法在真正需要它们的场景中被正确拉高或拉低。

6.2: Module decomposition

Stage-II mechanism-aware MAR-vs-MNAR soft gate 建议明确写成下面 4 个模块：

1. MM-prompt-to-gate projection
 - 直接读取 MM prompt，并结合轻量 local/global missingness summary，而不是再单独训练第四套独立 prompt encoder。
2. gate prompt construction
 - 将 MM prompt 与缺失统计通过轻量 gate head 投影为机制控制向量 p_{i}^{gate} 。
3. soft gate scoring
 - 对 OM 与 MM 两条核心分支输出归一化软权重。
4. regulated branch fusion
 - 在保留 OO foundation 的前提下，对 OM / MM 做机制感知的动态调节。

前人通常沿用统一恢复链路，而我们不再额外发明一套第四 prompt，而是直接从 MM prompt 派生 gate prompt：

$$p_i^{gate} = \psi_{gate}(p_i^{mm}, r_i)$$

根据该 gate prompt，第二阶段不再平均调三条分支，而是只动态调 OM 与 MM 的相对权重，OO 作为基础上下文始终参与。

6.3: OM-vs-MM soft regulation

$$[\beta_i^{om}, \beta_i^{mm}] = \text{Softmax}(W_g p_i^{gate})$$

其中：

$$\beta_i^{om} + \beta_i^{mm} = 1$$

于是最终融合直接写成：

$$z_i^* = z_i^{oo} + \beta_i^{om} z_i^{om} + \beta_i^{mm} z_i^{mm}$$

其直观语义是：

- 当样本更接近 MAR 时， β_i^{om} 更大，因此更偏 OO + OM
- 当样本更接近 MNAR 时， β_i^{mm} 更大，因此更偏 OO + MM
- 当样本机制模糊时，OM 与 MM 通过 soft weight 连续过渡

这正对应用户要求中的第二张图：前人统一处理，而我们在第二阶段只对 MAR 与 MNAR 做动态调节。

换句话说，第二阶段真正被动态拉高和拉低的是 OM 与 MM 两条核心创新分支，而 OO 始终作为基础 context path 参与恢复。

6.4: Explanation of every symbol

为了避免第二阶段再次被写成“一个抽象 gate”，这里也要把每个量解释清楚：

- p_i^{mm} ：来自 MM branch 的 missing-structure prompt，是第二阶段判断机制偏好的主语义来源。
- r_i ：轻量 local/global missingness summary，用于补充位置级缺失统计。
- $\psi_{gate}(\cdot)$ ：gate prompt encoder，用于把 MM prompt 与缺失统计映射为机制控制向量。
- p_i^{gate} ：位置 i 的 gate prompt，表达该位置更接近 MAR-like 还是 MNAR-like 恢复状态。
- W_g ：gate 参数矩阵，将机制提示映射为 OM/MM 两条分支的打分。
- $\beta_i^{om}, \beta_i^{mm}$ ：对 OM 与 MM 的软权重，满足二者和为 1。
- z_i^* ：融合后的最终主表征，表示在 OO anchor 保持不变的前提下，对 OM 与 MM 做机制感知调节后的恢复表征。

6.5: Why does it works

第二阶段之所以不能被简化成一个静态融合层，是因为真实缺失机制并不会在所有位置上都遵循同一种 dependency preference。对于更接近 MAR 的位置，observed-side interaction 往往更可信，因此模型应更依赖 OO + OM；而对于更接近 MNAR、长块缺失或带明显 missing-side structure 的位置，真正有价值的信号更多来自 OO + MM。如果仍然像 prior work 那样用一套统一恢复流程处理 MAR / MNAR / Mix，模型就会被迫对所有位置使用同一组固定融合规则，最终既无法充分利用 MM，也无法在 MAR-like 区域保持足够轻量 and 稳健。UniMiss 的 Stage-II mechanism-aware MAR-vs-MNAR soft gate 不是单独训练第四套 prompt，而是直接从 MM prompt 再结合轻量 missingness summary 派生出 gate prompt，将“当前更像哪种机制”显式写入计算图，只调 OM 与 MM 的相对权重，而不去重写 OO 的基础角色。这种设计之所以有效，是因为它把“不同机制应依赖不同分支”从隐式经验变成了可学习、可解释、可视化的显式决策，同时避免了 prompt 体系被写得过碎。

6.6: Difference from prior mechanism handling

前人常见做法是：无论缺失位置更接近 MAR、MNAR 还是两者混合，都由同一条恢复主干统一处理，最多依赖 backbone 自己去“顺带学会”机制差异。UniMiss 的不同点在于：我们把机制差异显式写成 mechanism-aware soft gate，让模型在 OO 不变的前提下，专门学习何时应拉高 OM、何时应拉高 MM；但这种 gate 又不是第四类独立 prompt family，而是由 MM prompt 外加轻量缺失统计派生出来。因此，机制信息不再是隐式噪声，而是进入了显式决策链，同时方法在叙事上也比“四套完全独立 prompt”更克制。

7: 解码器:

最终重建值为:

$$\hat{x}_i = D([z_i^*; \beta_i^{om}; \beta_i^{mm}; a_i])$$

其中:

- z_i^* 为二阶段融合后的主表征
- $\beta_i^{om}, \beta_i^{mm}$ 为 branch-level soft weights
- a_i 为 MM experts 输出的极值放大系数

这样设计的目的在于让 decoder 不只是“被动接收一个 fused hidden state”，而是显式知道:

- 当前更信哪个 branch
- 当前是否应该允许更大的 MNAR 偏移

其中 decoder 只需要完成一件事：把 OO foundational context path + regulated OM/MM innovation signals 映射回最终插补值，而不必再额外引入复杂的第三阶段。对于 MNAR 相关位置， a_i 可以继续作为幅度校正因子参与输出层，以避免极值与周期模式再次被过度平滑。

7.1 Why it works

decoder 在 UniMiss 中刻意保持轻量，是因为这套方法真正的有效性来自前面几条分支的结构分工，而不是把最后一层做成新的复杂主干。如果 decoder 过强，它反而会重新吞掉 `OO / OM / MM / gate` 已经形成的角色边界，让模型再次退化为“统一隐藏状态 -> 大解码器恢复”的 prior-style 设计。当前这种轻量 decoder 的作用是把已经被分工清楚的表征映射回数值空间，同时显式看到 branch soft weights 与极值校正项，因而既能保留前面结构设计可解释性，又不会把恢复责任重新压回最后一层。

8. 损失函数

为了避免损失项看起来像“功能堆叠”，正文主损失建议只保留 3 项，写成：

$$\mathcal{L} = \lambda_{rec} \mathcal{L}_{rec} + \lambda_{sep} \mathcal{L}_{sep} + \lambda_{gate} \mathcal{L}_{gate}$$

其中：

- 重建损失

$$\mathcal{L}_{rec} = \frac{1}{|\Omega|} \sum_{(t,d) \in \Omega} |\hat{X}_{t,d} - X_{t,d}^{gt}|$$

这里 Ω 表示评估缺失位置集合。为兼顾 MNAR 场景中的极值恢复，可直接在 $\mathcal{L}_{rec}$ 中使用位置权重 $sw_{t,d}$ ，而不再单独拆一个第四损失。

- 分支分离损失

$$\mathcal{L}_{sep} = \mathcal{L}_{con}(z^{oo}, z^{om}) + \mathcal{L}_{con}(z^{oo}, z^{mm}) + \mathcal{L}_{con}(z^{om}, z^{mm})$$

它服务于第五章强调的 decoupling，确保 `OO / OM / MM` 不是换名字的同表征。

- 机制调节损失

$$\mathcal{L}_{gate} = -\mathbb{E}_i [y_i^{mar} \log \beta_i^{om} + y_i^{mnar} \log \beta_i^{mm}]$$

其中 y_i^{mar} 与 y_i^{mnar} 并不一定需要严格人工标签，也可以由缺失统计量诱导生成弱监督目标。它的作用不是单独提升重建误差，而是约束第二阶段真的学到 `OM-vs-MM` 的 `MAR-vs-MNAR` 动态偏好。

这样一来，正文只保留 `L_rec + L_sep + L_gate` 三项主损失，结构更克制，也更像正式论文方法章节。

8.1: Why does it works

损失函数之所以只保留 `L_rec + L_sep + L_gate` 三项，是为了让训练目标与方法结构一一对应，而不是通过堆叠大量 auxiliary losses 来“补救”结构设计本身的不清晰。`L_rec` 对应最终重建质量，保证模型真的把表征转化成更好的恢复结果；`L_sep` 对应 branch decoupling，保证 `OO / OM / MM` 的功能分工不会在训练中塌缩；`L_gate` 对应 mechanism-aware regulation，保证第二阶段学到的不是任意权重，而是与 `MAR-vs-MNAR` 偏好相关的可解释调节。也就是说，这三项损失并不是附加修饰，而是分别对应“恢复得准、角色分得开、机制调得对”这三个核心目标。

2.3: 复杂度分析：

- N_{obs} : observed token 数
- N_{mis} : missing token 数
- d : 隐藏维度
- L_{oo} : OO encoder 层数
- K_{om}, K_{mm} : 两类 expert family 的 expert 数
- C : 每个 missing token 在 OM 中检索的 observed candidate 数
- E_m : missing topology 稀疏图中的边数

则主要复杂度可以写为：

1. OO branch

$$\mathcal{O}(L_{oo}N_{obs}^2d) + \mathcal{O}(N_{obs}d^2)$$

第一项来自 observed-only context encoding，第二项来自 foundation path 中的 prompt-conditioned projection 与 pattern-aware anchoring。

2. OM branch

$$\mathcal{O}(N_{mis}Cd) + \mathcal{O}(K_{om}N_{mis}d^2)$$

它主要由局部 observed candidate bank 与 OM experts 构成，因此不需要全局 full attention。

3. MM branch

$$\mathcal{O}(E_md) + \mathcal{O}(K_{mm}N_{mis}d^2)$$

其中前一项来自 missing topology aggregation，后一项来自三类 MM experts。

4. Stage-II gate + decoder

$$\mathcal{O}(N_{mis}d^2)$$

这里之所以没有再额外写一项独立 mechanism prompt encoder 的复杂度，就是因为 Stage-II 的 gate prompt 由 MM prompt + r_i 轻量派生，只新增一个小型 gate head。因此，若采用局部候选集与稀疏 missing graph，模型的主复杂度仍集中在 OO foundation，而 OM / MM / gate 的额外代价是可控的。这与“参数量不大但结构新颖”的目标一致。

2.4：伪代码算法流程：

代码块

```
1  ``text
2  Algorithm 1 Unimiss Forward Pass
3  Input:
4      time series X, observation mask M
```

```

5  Output:
6      imputed sequence X_hat
7
8  1: H0 <- FuseValueTimeMask(X, M, E_t, E_d)
9  2: p_oo_i <- BuildOOPrompt(H0, M)
10 3: z_oo_i <- OOFoundationEncoder(H0_i, p_oo_i)
11
12 4: For each missing token i do
13 5:   C_i_obs <- RetrieveObservedCandidates(H0, M, i)
14 6:   x_nb_i <- AggregateObservedSummary(C_i_obs)
15 7:   p_om_i <- BuildOMPrompt(m_i, r_i, x_nb_i, z_oo_i)
16 8:   w_om_i <- OM_Router(p_om_i, z_oo_i)
17 9:   z_om_i <- Sum_k w_om_i[k] * OM_Expert_k(p_om_i, z_oo_i)
18 10: End For
19
20 11: [s_topo, s_ext, s_per] <- BuildMissingSidePromptSources(M)
21 12: For each missing token i do
22 13:   p_mm_i <- BuildMMPrompt(z_oo_i, s_topo, s_ext, s_per)
23 14:   w_mm_i <- MM_Router(p_mm_i, z_oo_i)
24 15:   z_mm_i <- Sum_k w_mm_i[k] * MM_Expert_k(z_oo_i, p_mm_i)
25 16:   p_gate_i <- BuildGatePrompt(p_mm_i, r_i)
26 17:   [beta_om_i, beta_mm_i] <- SoftGate(p_gate_i)
27 18:   a_i <- ExtremeAmplitudeHead(z_mm_i)
28 19:   z_i* <- z_oo_i + beta_om_i * z_om_i + beta_mm_i * z_mm_i
29 20:   x_hat_i <- Decoder(z_i*, beta_om_i, beta_mm_i, a_i)
30 21: End For
31 22: Compute L_rec + L_sep + L_gate
32 23: Return X_hat and losses
33 ```

```

2.5: 补充:

1.为什么O-O不和O-M&M-M一样同样设计为Expert架构?

O-O 之所以不采用 expert 架构，是因为它的职责在于提供稳定共享的 observed anchor，而不是执行高异质、位置敏感的恢复决策。相反，O-M 与 M-M 之所以采用 expert 化设计，是因为不同缺失位置对 observed evidence 和 missing-side structure 的需求本来就不同。

2.test

3.Experiment:

3.0：实验设置：

还是使用两个数据集IAQ和ETT；三种缺失率20，30，40；三种机制MAR，MNAR，Mix（视情况而定，可将MAR结果放至附录中）其中Mix的逻辑是先MNAR后MAR

这次跑三个种子3407，3408，3409（取三个种子的平均）

注意实验要记录方差：记录 mean ± std（以下所有实验都要记录）

增加MAPE指标，删除Wasserstein

注意数据原始MCAR缺失率要调为0，避免出现信息过渡缺失；

对于Mix的实验设置目前来看采用对半的缺失率：

比如：而且如果两个缺失机制不平衡的话，肯定模型识别能力就没什么必要了，比如如果MAR占主体，那模型针对MNAR的少部分几乎用MAR来填补也不会有什么问题了

Mix放在主表，其他两个放在附录

关于P值statistical significance添加问题；以及MAPE指标调整

MAR应该不止局限于变量间，更应该有同一变量的可观测导致缺失（可观测导致缺失）

要思考一下，由于我们的Gate_loss，是否在缺失机制的设计上，需要明确标签？

（初始缺失率调整为0.01，并配置对应模型的标准超参）

修改：（1）：仿照现有场景，新增Mix场景，即先进行MNAR逻辑，再进行MAR逻辑；具有20，30，40三种缺失率，并且MNAR与MAR对半；（2）实验的五个种子改为三个取平均，3407，3408和3409；（3）：实验结果要记录方差：记录 mean ± std，也就是指标结果是有加减方差的；（4）：增加MAPE的metric指标（MAPE 不乘 100，而是按比例值输出，所以数值会从原来的“百分比量级”变成接近 0~1 的小数尺度），删除wasserstein_distance的指标；（5）在toml文件中添加，针对IAQ，ETT两个数据集的Mix场景，20，30，40的任务配置（6）删掉physionet和pems_traffic的相关内容，以及mnar_nonuniform

FGTI/SPIN/MTSCI修改代码整理 ---- 整理完毕所有 Baseline ---- 接下来同步开展实验运行+模型设计

3.1：实验主表：

Datase ts	Missin g_rate	Metri c	Mean	BRIT S	SPIN	Time sNet	SAIT S	Impute Former	MTSC I	FGTI	Sup er
	20%-4 0%		Heuri stic	2018 NIPS	NIPS	2023I CLR	2023 ESW	2024KD D	2024C IKM	2025N IPS	Ours

							A				
ETT (MAR)	20%	RMSE MAE MRE MAPE									
	30%	RMSE MAE MRE MAPE									
	40%	RMSE MAE MRE MAPE									
IAQ (MAR)	20%	RMSE MAE MRE MAPE									
	30%	RMSE MAE MRE MAPE									
	40%	RMSE MAE MRE MAPE									

Datase ts	Missin g_rate 20%-4 0%	Metri c	Mean Heurist ic	BRIT S 2018 NIPS	SPIN 2022 NIPS	Time sNet 2023 ICLR	SAIT S 2023 ESW A	Impute Former 2024K DD	MTSC I 2024 CIKM	FGTI 2025NIP S	Sup er Ours
--------------	-------------------------------------	------------	---------------------------	-------------------------------	----------------------	----------------------------------	-----------------------------------	-------------------------------------	-------------------------------	--------------------------	-----------------------

ETT (MNA R_t)	20%	RMS								
		E								
		MAE								
		MRE								
		MAP								
		E								
	30%	RMS								
		E								
		MAE								
		MRE								
		MAP								
		E								
	40%	RMS								
		E								
		MAE								
		MRE								
IAQ (MNA R_x)	20%	RMS								
		E								
		MAE								
		MRE								
		MAP								
		E								
	30%	RMS								
		E								
		MAE								
		MRE								
		MAP								
		E								
	40%	RMS								
		E								
		MAE								
		MRE								

		MRE									
		MAP									
		E									
	40%	RMS									
		E									
		MAE									
		MRE									
		MAP									
		E									

3.2：消融实验：

保留下面 4 个主消融：

1. w/o OO foundation
 - 将 OO 分支退化为普通 shared backbone，去掉其 pattern-aware observed-side anchoring。
2. w/o OM interaction routing
3. w/o MM experts
4. w/o Stage-II mechanism-aware MAR-vs-MNAR soft gate

其余组件如 graph prior、periodic evidence encoder、consistency loss、separation loss 都不再单独抬成“大模块”，只作为 support component 或损失项出现。

3.3：超参数实验：

建议只保留 2-3 组最关键的超参数，避免把实验面铺得过宽：

1. expert number / branch capacity
 - 验证 OM / MM experts 在小规模下也有效，而不是靠堆很多专家取胜。
2. gate temperature / softness
 - 验证第二阶段需要 soft regulation，而不是 hard switching。
3. MM expert capacity
 - 例如 pattern-bank size、hidden width 或 periodic evidence weight。
 - 目标是证明 MM 不需要做得很大也能起作用。

3.4：可视化实验：

建议在 Mix 场景下至少保留 3 类可视化：

1. sample-level gate weight distribution
 - 展示不同样本上 β^{om} 与 β^{mm} 的分配差异，并说明 OO 始终保留。
2. MAR-like vs MNAR-like segment case study
 - 在同一条混合缺失序列中，展示更偏 MAR 的区段为什么更依赖 OO+OM，更偏 MNAR 的区段为什么更依赖 OO+MM。
3. mechanism prompt projection
 - 使用 PCA / t-SNE 或 prompt-score plotting 展示 mechanism prompt 与 gate 输出的对应关系。

这些图的目标都只有一个：证明第二阶段不是黑箱，而是真的在 Mix 中学到了 MAR-vs-MNAR 的局部动态调节。

3.5: Lightweight&Scalable实验：

这一小节不能写成“顺手压缩一下模型看看行不行”，而要明确回答：**UniMiss 的有效性究竟来自结构分工，还是主要来自更大的参数量与更重的计算。** 如果一个方法只有在大 hidden width、大 expert 数、复杂 gate 下才成立，那么它更像“高容量模型碰巧有效”；相反，如果 `OO foundational context path + OM/MM dual-core experts + Stage-II mechanism-aware MAR-vs-MNAR soft gate` 在轻量配置下仍能稳定保留主要收益，才能证明 UniMiss 的核心价值来自 dependency decomposition 本身，而不是纯粹堆大模型。

建议把 Lightweight 版本压成 3 级配置，而不是只给一个“tiny setting”：

1. Lite-S
 - 仅保留最小 OM / MM expert 数，例如把 K_{om} ， K_{mm} 同时减半；
 - 将 branch hidden width 从 d 压缩到 $d/2$ ；
 - gate MLP 从两层改为单层线性映射。
2. Lite-M
 - 保持 branch 数不变，但共享部分 prompt encoder 参数；
 - 对 OM router 与 MM router 采用低秩投影或 bottleneck 映射；
 - decoder 继续保持轻量，避免把收益重新转移到末端大解码器。
3. Lite-Shared
 - 保留 OO 不变；
 - 将 OM / MM 内部部分 expert 前层共享，仅保留末端 specialization head；
 - 验证“共享基础 + 少量专门化”是否已足以支撑方法主收益。

若把完整模型记为：

$\text{UniMiss}(d, K_{om}, K_{mm}, d_g),$

则轻量化版本可写成：

$\text{UniMiss-Lite}(\gamma_d d, \gamma_{om} K_{om}, \gamma_{mm} K_{mm}, \gamma_g d_g),$

其中 $\gamma_d, \gamma_{om}, \gamma_{mm}, \gamma_g \in (0, 1]$ 分别控制 hidden width、OM experts 数、MM experts 数和 gate 容量。这样写的好处是，正文里可以清楚表达“我们是在系统压缩不同结构位点”，而不是含糊地说“做一个轻量版”。

评测指标建议同时报告：

- reconstruction quality：MAE / RMSE / MRE / MAPE
- efficiency：参数量、FLOPs、GPU memory、单 batch latency
- robustness under compression：相对 full model 的性能下降幅度
- structural retention：gate 分布是否仍能分开 MAR-like 与 MNAR-like 区域

比较对象建议至少包括：

- UniMiss-Full
- UniMiss-Lite
- 参数量对齐的 prior baseline，例如压缩版 SAITS / TimesNet / ImputeFormer

这一组实验真正想验证的不是“谁最小”，而是三件事：

- 当 $K_{\{om\}}$ 与 $K_{\{mm\}}$ 降低时，性能是否平滑退化，而不是立即塌缩；
- 在轻量场景下，Stage-II gate 是否仍然有贡献，说明动态调节不是奢侈模块；
- MM 是否在压缩后仍能保住 MNAR / Mix 下的关键收益，说明 missing-structure modeling 不是可有可无的装饰。

如果结果成立，最有力的结论应写成：****UniMiss 的优势主要来自结构化的 dependency-aware 分工，因此即使在资源受限配置下，`OO` 提供稳定 observed anchor、`OM/MM` 提供定向 specialized modeling、`Stage-II` 提供机制感知调节的基本逻辑仍然成立。*** 这会直接增强方法的 deployability 叙事，也使论文不再显得只适合“大模型 + 大算力”环境。

Scalability 不能只理解成“换更大数据集试一下”，它需要单独验证 UniMiss 在多种规模轴上是否仍保持合理的质量-复杂度折中。对于时序插补而言，最关键的扩展维度通常不是单一的数据量，而是：时间长度更长、变量维度更多、缺失率更高、缺失块更复杂，以及在这些条件叠加时 `OM / MM / gate` 是否还能维持清晰分工。因此，这一小节的核心问题是：**UniMiss 是否只在当前中等规模 setting 下成立，还是能在更难、更大、更复杂的 imputation regime 中稳定扩展。**

建议至少沿下面 4 条规模轴做系统实验：

- temporal scale
 - 将序列长度从 T 扩展到 $\{2T, 4T\}$ ；

- 关注 `00` foundation 与 `0M` candidate retrieval 在长上下文下是否仍稳定。

2. `variable scale`

- 将变量数从 D 扩展到更高维设定；
- 关注 cross-variable cue 增多后，`0M` 是否更有价值，router 是否出现过载。

3. `missing-pattern scale`

- 同时提高 missing ratio、缺失块长度与 mixed mechanism complexity；
- 重点观察 `MM` 与 `Stage-II gate` 是否随着缺失机制复杂化而变得更关键。

4. `expert scale`

- 改变 `K_{om}`，`K_{mm}` 或 branch capacity；
- 观察专家数增大后是否仍有稳定收益，还是很快进入冗余区间。

结合第 `6.10` 节复杂度分析，这里建议把扩展趋势写成“精度曲线 + 代价曲线”双视角，而不是只报最终精度。对于每一条规模轴，都应同步报告：

- `quality trend`： `MAE / RMSE` 随规模变化的曲线
- `cost trend`：训练时间、推理时间、显存占用、吞吐变化
- `routing trend`： `0M / MM` 使用频率、gate weight 分布、expert utilization
- `stability trend`：不同 seed 下方差是否显著扩大

Mix下不同的混合探索

4.写作：

相关工作中可以将用MAR来评估MNAR的部分也提出来